


- Under/Over complete \rightarrow # latent
 $\hookrightarrow h < v \hookrightarrow h > v$

\rightarrow MSE $\hat{x} \leftarrow x$

\rightarrow cross ent. \rightarrow bin



Advanced
Institute for
Artificial
Intelligence

Autoencoders II

Advanced Institute for Artificial Intelligence – AI2

<https://advancedinstitute.ai>




Variational Autoencoders

Variational Autoencoders

Recapitulando: O problema com o autoencoder padrão

- Além de algumas aplicações eficientes como denoising autoencoders eles são bastante limitados;
- O espaço latente para o qual convertem suas entradas e onde estão seus vetores de encoding podem não ser contínuo ou permitir fácil interpolação.
- Por exemplo, treinar um autoencoder no conjunto de dados MNIST e visualizar as codificações de um espaço latente 2D revela a formação de clusters distintos:



Recapitulando: O problema com o autoencoder padrão

- Ao construir um modelo generativo, não queremos replicar os dados de entrada:
 - Amostrar aleatoriamente do espaço latente, ou
 - Gerar variações em uma imagem de entrada, a partir de um espaço latente contínuo;
- Se o espaço tiver descontinuidades e você amostrar/gerar uma variação a partir daí, o decoder simplesmente gerará uma saída irreal;
 - O decoder não tem ideia de como lidar com aquela região do espaço latente;
 - Durante o treinamento, nunca viu vetores codificados vindos daquela região do espaço latente;

Definições

- Os Variational Autoencoders (VAEs) têm uma propriedade fundamentalmente única que os separa dos autoencoders comuns:
- Seus espaços latentes são, por desenvolvimento, contínuos;
 - A continuidade do espaço latente permite fácil amostragem aleatória e interpolação.
- Seu encoder não produz um vetor de codificação de tamanho n ; $\rightarrow n/2$
- Em vez disso, ele gera dois vetores de tamanho n :
- um vetor de médias, μ , e
 - outro vetor de desvios padrão, σ .
 - A média e o desvio padrão da i -ésima variável aleatória, X_i da qual amostramos, para obter a codificação amostrada que passamos para o decodificador;
- Handwritten notes:* $Z \sim N, B$ (with an arrow pointing to the first bullet point), $N(\mu, \sigma)$ (with an arrow pointing to the second and third bullet points), and a sketch of a normal distribution curve.

Variational Autoencoders

Definições




Figure: Variational Autoencoder com os vetores μ e σ .

Fonte: Variational Autoencoder architecture by Irhum

Variational Autoencoders

Example

No cenário onde temos um sinal de entrada com 500 características e pretendemos reduzir esse sinal para apenas 30, poderíamos pensar em construir um VAE da seguinte forma:




Figure: VAE que reduz as 500 dimensões de entrada para 30 dimensões no espaço latente.

Variational Autoencoders

Definições




Figure: Como o passo forward funciona.

Variational Autoencoders

Definições

- Geração estocástica de vetores de codificação.
 - Para a mesma entrada, mantendo a média e o desvio padrão iguais, a codificação real irá variar em cada passagem devido à amostragem.
- O vetor da média controla onde a codificação de uma entrada deve ser centralizada;
- O desvio padrão controla quanto da média a codificação pode variar (a área)




Figure: μ e σ para controlar a amostragem.

Definições

- Não apenas um único ponto no espaço latente se refere a uma amostra dessa classe.
- Todos os pontos próximos se referem ao mesmo em um raio- σ ;
- O objetivo aqui é tentar criar um espaço latente mais homogêneo, eliminando a descontinuidade;
 - O modelo está agora exposto a um certo grau de variação local variando o encoding de uma amostra;
 - Queremos sobreposição entre amostras que também não sejam muito semelhantes;
 - Interpolação entre classes;

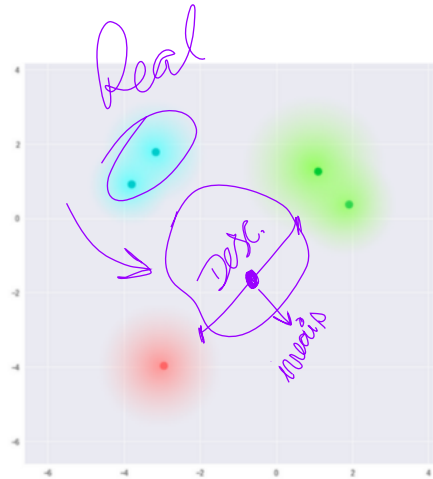

Definições

- Não há limites para os valores que os vetores μ e σ podem assumir:
 - Encoder pode aprender a gerar μ muito diferentes para diferentes classes, agrupando-as e minimizando σ
 - Pode chegar a um ponto que parece um único ponto.
- Desejável: Codificações que sejam o mais próximas possível e ainda assim distintas, permitindo uma interpolação suave e possibilitando a construção de novas amostras.

Variational Autoencoders

Definições

O que queremos e o que podemos obter:



Definições - A divergência KL

□ Kullback-Leibler divergence $KL \geq 0$

$$KL(q||p) = -\sum q \log \frac{q}{p}$$

□ Mede o quanto eles divergem entre si;

□ Para VAEs, o custo pela KL é equivalente à soma de todas as divergências KL entre a componente $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ e a normal padrão.

- Essa medida é minimizada quando $\mu_i = 0$ e $\sigma_i = 0$

□ Quando a divergência é calculada entre distribuições univariadas, ela pode ser simplificada para [1]:

$$\sum_{i=1}^n \sigma_i^2 + \mu_i^2 - \log(\sigma_i^2) - 1$$

[1] *Deriving the KL divergence loss for VAEs*

Definições - A divergência KL

- ❑ Essa perda força o encoder a distribuir todas as codificações uniformemente ao redor do centro do espaço latente;
- ❑ Usar puramente o resultado da loss KL resulta em um espaço latente com codificações densamente colocadas aleatoriamente, perto do centro do espaço latente;
- ❑ O decoder acha impossível decodificar qualquer coisa significativa deste espaço;




Figure: Espaço latente produzido por um VAE treinado apenas com a loss KL.

Variational Autoencoders

Agrupando as informações...

- Utilizar a divergência KL como mecanismo de penalização;
- Otimizar a loss composta (por exemplo reconstrução, ou entropia-cruzada) e a divergência KL;
 - Geração de um espaço latente que mantém a semelhança das codificações próximas;
 - Globalmente, é densamente compactado perto da origem do espaço latente;
 - Equilíbrio alcançado pela natureza formadora de agrupamentos da loss de reconstrução e pela natureza de empacotamento denso da loss KL;

mse




Figure: Empregando a loss combinada.


Variational Autoencoder

Um pouco da matemática dos VAE:

$$\rightarrow H = -\sum p(x) \log P(x)$$



$$\rightarrow KL(q||p) = -\sum q \log \frac{p}{q}$$



$$P(z|x) = \frac{P(x|z) P(z)}{P(x)} = \frac{P(x,z)}{P(x)} \quad (1)$$

Monitor MCMC
6.66
VI \rightarrow KL

$$(2) KL(q(z)||p(z|x)) = -\sum q(z) \log \frac{P(z|x)}{q(z)}, \text{ Subst. 1}$$

$$= -\sum_z q(z) \log \frac{P(x,z)}{P(x) q(z)} = -\sum_z q(z) \left[\log \frac{P(x,z)}{q(z)} + \log \frac{1}{P(x)} \right]$$

$$\Rightarrow KL = -\sum_z q(z) \log \frac{P(x,z)}{q(z)} + \sum_z q(z) \log P(x) \rightarrow$$

Um pouco da matemática dos VAE:

$$KL = - \sum q(z) \log \frac{P(x|z)}{q(z)} + \sum q(z) \log P(x) = - \sum q(z) \log \frac{P(x|z)}{q(z)} + \log P(x)$$

↓ dist. Prob

$$\log P(x) = \sum q(z) \log \frac{P(x|z)}{q(z)} + KL(q(z) \| p(z|x)) \quad (3)$$

Diagram illustrating the components of the ELBO (Evidence Lower Bound) equation (3):

- $\log P(x)$ is the total log-likelihood.
- $\sum q(z) \log \frac{P(x|z)}{q(z)}$ is the reconstruction loss, which is maximized (indicated by a red arrow labeled "max").
- $KL(q(z) \| p(z|x))$ is the Kullback-Leibler divergence, which is minimized (indicated by a red arrow labeled "min").
- The total loss is denoted by \mathcal{L} (indicated by a red arrow labeled "L").

$$\mathcal{L} = \sum q(z) \log \frac{P(x|z)P(z)}{q(z)} \Rightarrow \mathcal{L} = \sum q(z) \left[\log \frac{P(x|z)}{q(z)} + \log P(z) \right] \Rightarrow \mathcal{L} = \sum q(z) \frac{\log P(z)}{q(z)} + \sum q(z) \log P(x|z)$$

Diagram illustrating the components of the ELBO equation:

- $\sum q(z) \log \frac{P(x|z)}{q(z)}$ is the reconstruction loss, which is maximized (indicated by a red arrow labeled "max").
- $\sum q(z) \log P(z)$ is the KL divergence, which is minimized (indicated by a red arrow labeled "min").
- The total loss is denoted by \mathcal{L} (indicated by a red arrow labeled "L").

$$\frac{P(x|z)P(z)}{P(x)} = \frac{P(x,z)}{P(x)}$$

$$\Rightarrow P(x,z) = P(x|z)P(z) \quad (4)$$


$$-KL(q(z) \| p(z)) \quad \text{KL} \quad \text{MSE} \quad E_q \log P(x|z)$$

Diagram illustrating the components of the ELBO equation:

- $-KL(q(z) \| p(z))$ is the KL divergence, which is minimized (indicated by a red arrow labeled "min").
- $E_q \log P(x|z)$ is the reconstruction loss, which is maximized (indicated by a red arrow labeled "max").
- The total loss is denoted by \mathcal{L} (indicated by a red arrow labeled "L").

Variational Autoencoder

Um pouco da matemática dos VAE:



$$z \sim \mathcal{N}(\mu, \sigma) \rightarrow \mathcal{N}(\mu, \Sigma)$$

$$q(z|x) = \frac{q(x|z)q(z)}{q(x)} \rightarrow q(z) = \frac{q(z|x)q(x)}{q(x|z)}$$

$$E_{q(z)} \log p(\hat{x}|z) = E_q \log (e^{-\frac{1}{2\sigma^2} \|x - \hat{x}\|^2})$$

$$E_q \|x - \hat{x}\|^2$$

$$z \sim \mathcal{N} \rightarrow \mathcal{L}^{\frac{\|x - \hat{x}\|^2}{2}} \rightarrow \boxed{\|x - \hat{x}\|^2}$$



Reparam.
trick

$$z = \mu + \sigma \cdot \mathcal{N}(0, 1)$$

Um pouco da matemática dos VAE:

-
-
-
-
-
-
-
-

Um pouco da matemática dos VAE:

-
-
-
-
-
-
-
-

Um pouco da matemática dos VAE:

-
-
-
-
-
-
-
-

Um pouco da matemática dos VAE:

-
-
-
-
-
-
-
-

Um pouco da matemática dos VAE:

-
-
-
-
-
-
-
-